

一、資料前處理

1. 針對 members 資料的處理

members 資料提供了使用者的基本資訊，如城市、註冊方式、年齡(bd)和性別等。這些變數直接影響使用者行為，因此需要進行處理以便後續特徵工程。

- 移除無效數據：
使用 dropna 移除 city 和 registered_via 中的缺失值，因為這些變數對使用者的行為至關重要。
移除 registration_init_time 中的缺失值，因為這是進行日期計算的關鍵變數。
- 處理日期格式：
registration_init_time 原始資料為整數格式，必須轉換為日期格式。將其轉換為 datetime 格式後，可以用來計算距離某個參考日期的天數，這可用來推測使用者使用服務的時長。
- 移除不必要的變數：
我們選擇移除 bd(年齡)和 gender(性別)，因為這些變數可能存在異常值或缺失值較多，且不利於模型建構。

2. 針對 train 和 train_v2 資料的處理

train 和 train_v2 資料是我們的訓練集，包含了用戶是否流失的標籤(is_churn)。

- 合併 members 資料：
我們使用 msno 作為鍵，將 train 和 members 資料進行合併，這樣可以獲取每個用戶的城市、註冊方式和註冊時間等資訊。
- 特徵工程：
使用註冊時間計算使用者從註冊到截止日期(如2017-03-31或2017-11-13)的天數，這個特徵可用來推測使用者對平台的活躍度。
- 移除不必要變數：
和處理 members 資料時一樣，移除了 bd 和 gender 等不必要的變數。

3. 針對 transactions 資料的處理

transactions 資料集提供了用戶的付款歷史，這對於了解用戶的訂閱行為非常重要。

- 處理日期格式：
將 transaction_date 和 membership_expire_date 轉換為 datetime 格式，這有助於後續的特徵計算。
- 特徵工程：
計算每個交易的有效期限長度(plan_date)，即訂閱開始日期和結束日期之間的天數，這可作為用戶忠誠度的一個指標。
- 移除不必要變數：

移除了 transaction_date 和 membership_expire_date, 因為這些日期已經轉化為其他有意義的特徵。

4. 針對 test 資料的處理

test 資料集是我們的測試集, 包含了要預測的用戶流失狀況。處理方式類似於訓練資料。

二、特徵挑選與工程

在特徵工程過程中, 我們選擇了以下幾個重要的變數:

- 城市(city): 用戶所在的城市, 可能影響用戶行為。
- 註冊方式(registered_via): 用戶通過哪種方式註冊, 這可能反映了用戶的技術熟悉度或渠道差異。
- 註冊時間差異(date): 用戶從註冊到訓練或測試截至日期的天數, 反映了用戶使用服務的持續時間。
- 訂閱有效期(plan_date): 用戶每次交易的訂閱有效期天數, 這反映了用戶對服務的持久度或忠誠度。

三、合併數據

最後, 將所有資料合併起來, 包含訓練、交易和測試資料, 以建立一個完整的資料集。這樣, 我們可以更好地分析影響用戶流失的因素, 並進行模型訓練與預測。

四、建立模型

我們首先使用了Random Forest想簡單嘗試預測能力; 發現我們的資料集並非線性的, 因此改嘗試XGBoost及SVM模型。

五、預測結果

The validation accuracy of XGB: 0.95.
log loss is 0.1660.